Tecnológico Nacional de México / Instituto Tecnológico de Culiacán.



Ingeniería en Sistemas Computacionales.

Inteligencia Artificial

Zuriel Dathan Mora Felix.

Modulo 2

Detección de Spam

Ontiveros Sánchez Jesús Daniel (22170750).

Ramírez Ruiz Santiago (22170783).

Horario de 9:00 a 10:00 AM.

Culiacán Sinaloa a 12 de octubre del 2025

Documentación de Código de Detección de Spam

Archivo DeteccionDeSpam.py

Es el archivo donde se realizo la parte del backend para hacer los cálculos las funciones de limpieza, calcular probabilidades, etc.

Librerías utilizadas

Función de limpieza del texto

Estas funciones preparan el texto para el análisis: eliminan acentos, mayúsculas, caracteres raros y espacios innecesarios.

Esto garantiza que el modelo procese solo palabras limpias y uniformes.

Funciones de Extracción

```
def dominio_de_email(remitente: str) -> str:  # Extrae el dominio del
correo (después del @)
   r = (remitente or "").strip().lower()
                                             # Limpia y pone en
minúsculas el remitente
   if "@" in r:
                                              # Verifica que contenga
       return r.split("@", 1)[-1]
                                              # Retorna el dominio
(parte después del @)
   return ""
                                              # Si no, retorna cadena
vacía
def tokens_dominio(dom: str) -> list[str]:  # Convierte dominio en
tokens útiles
   if not dom:
                                              # Si está vacío, devuelve
lista vacía
       return []
   dom = dom.replace("-", " ")
                                              # Reemplaza guiones por
espacios
                                              # Separa dominio por
   partes = dom.split(".")
                                              # Inicializa lista de
   toks = []
   if len(partes) >= 1:
       toks.append(f"from_dom_{limpiar_texto(partes[-2] if len(partes)>=2
else partes[0])}") # Token dominio
   if len(partes) >= 2:
                                              # Si hay TLD
       toks.append(f"from_tld_{limpiar_texto(partes[-1])}")  # Token del
TLD (.com, .org)
   if len(partes) >= 3:
                                              # Si hay subdominio
       toks.append(f"from_sub_{limpiar_texto(partes[0])}")  # Token
   return toks
                                              # Retorna la lista de
def extraer_enlaces(texto: str) -> list[str]: # Extrae URLs del texto
   return URL_RE.findall(texto or "")
                                              # Aplica expresión
regular definida en Config_regex
def tokens_enlace(url: str) -> list[str]:  # Convierte una URL en
```

```
toks = ["has_url"]
                                                  # Token que indica
presencia de URL
                                                  # Control de errores
       m = re.search(r"https?://([^/\s:]+)", url, re.I) # Busca el dominio
dentro de la URL
       if not m:
                                                  # Si no encuentra,
retorna token base
           return toks
       host = m.group(1).lower()
                                                 # Obtiene dominio
principal
       host = host.replace("www.", "")
                                                 # Elimina "www."
       partes = host.split(".")
                                                 # Separa por puntos
       if len(partes) >= 1:
                                                  # Token de dominio
           toks.append(f"url_dom_{limpiar_texto(partes[-2] if
len(partes)>=2 else partes[0])}")
       if len(partes) >= 2:
                                                  # Token de TLD
           toks.append(f"url_tld_{limpiar_texto(partes[-1])}")
       if len(partes) >= 3:
           toks.append(f"url_sub_{limpiar_texto(partes[0])}")
                                                  # Si ocurre error, ignora
   except Exception:
       pass
   return toks
                                                  # Devuelve lista de
def extraer_adjuntos(texto: str) -> list[tuple[str,str]]: # Extrae nombres
y extensiones de adjuntos
   adjuntos = []
                                                 # Lista vacía
   for m in ADJUNTO_RE.finditer(texto or ""): # Busca coincidencias
usando regex
       nombre = (m.group("name") or "").strip() # Obtiene nombre del
archivo
       ext = (m.group("ext") or "").lower().strip() # Obtiene extension
       if nombre and ext:
                                                 # Si ambos existen
           adjuntos.append((nombre, ext))
                                                 # Añade como tupla
(nombre, extensión)
   return adjuntos
                                                  # Devuelve lista de
adjuntos
def tokens_adjuntos(adjuntos: list[tuple[str,str]]) -> list[str]: #
Convierte adjuntos a tokens
   toks = []
                                                  # Lista vacía
   if adjuntos:
                                                 # Si hay adjuntos
       toks.append("has_attachment")
                                                 # Marca que hay adjuntos
    for nombre, ext in adjuntos:
                                                 # Recorre cada adjunto
       toks.append(f"att ext {ext}")
                                                 # Token con la extensión
```

```
if ext in EXT_PELIGROSAS:
                                                  # Si la extensión es
peligrosa
           toks.append("att_ext_dangerous")
                                                  # Añade token de peligro
       base = limpiar_texto(re.sub(r"\.[a-z0-9]{1,6}$", "", nombre,
flags=re.I)) # Limpia nombre base
       if base:
           for w in base.split():
                                                  # Divide en palabras
               if len(w) >= 3:
                                                  # Evita palabras cortas
                   toks.append(f"att_name_{w}") # Añade token con nombre
del adjunto
                                                  # Retorna lista final
   return toks
```

Estas funciones extraen partes importantes del correo:

- Dominio del remitente (por ejemplo, "gmail.com").
- Enlaces en el cuerpo del mensaje.
- Archivos adjuntos y sus extensiones.

Convierten esos datos en tokens (palabras clave) que el modelo usa para aprender patrones típicos del spam, como dominios falsos o extensiones peligrosas (.bat, .cmd, .exe).

Clase EmailSpamClassifier

```
------ CLASE PRINCIPAL ------
class EmailSpamClassifier:
                                                # Define clase principal
del clasificador
   def __init__(self, csv_path=None):
                                                # Constructor con ruta
opcional al dataset
       try:
           nltk.data.find("corpora/stopwords") # Verifica corpus de
stopwords
       except LookupError:
           nltk.download("stopwords")
                                                 # Descarga si no está
           nltk.data.find("tokenizers/punkt")
                                                 # Verifica tokenizer
       except LookupError:
           nltk.download("punkt")
                                                 # Descarga si falta
       self.precision = 0.0
                                                 # Inicializa precisión
       self.recall_spam = 0.0
spam
```

```
if csv_path is None:
                                                    # Si no se pasa CSV
           try:
               base = Path( file ).resolve().parent # Usa ruta del
archivo actual
           except NameError:
                base = Path(os.getcwd())
                                                     # O directorio actual
            csv_path = base / "datasets" / "spam_ham_dataset2.csv" # Ruta
por defecto
       self.csv_path = Path(csv_path)
                                                   # Guarda ruta del CSV
                                                   # Si el archivo existe
        if self.csv_path.exists():
           df = pd.read_csv(self.csv_path)
                                                   # Carga dataset
        else:
dataset de ejemplo
           df = pd.DataFrame({
                "remitente": [
                    "promos@casino-oro.fun",
                    "maria.garcia@empresa.com",
                    "soporte@seguridadbancaria-alerta.com",
                    "contabilidad@empresa.com",
                ],
                "asunto": [
                    "100 tiradas gratis sin depósito",
                    "Reunión semanal del equipo",
                    "Verifica tu cuenta urgente",
                    "Reporte mensual",
                ],
                "mensaje": [
                    "Registrate y gana premios al instante. premios.bat", #
archivo .bat peligroso
                    "Nos vemos mañana 10:00 sala de juntas. reporte.pdf",
                    "Detectamos actividad inusual. verificar-cuenta.cmd",
archivo .cmd peligroso
                    "Envío el reporte mensual consolidado. balance.xlsx",
                ],
                "enlaces": [
                    "https://casino-oro.fun/oferta",
                    "https://seguridadbancaria-alerta.com/verificar-cuenta",
                "etiqueta": ["spam", "ham", "spam", "ham"], # Etiquetas
reales
```

```
if "etiqueta" not in df.columns:  # Verifica existencia de
columna etiqueta
           raise ValueError("El CSV debe contener la columna 'etiqueta' con
valores 'spam' o 'ham'.")
       df["remitente"] = df.get("remitente", "").astype(str) # Convierte
remitente a texto
       df["asunto"] = df.get("asunto", "").astype(str) # Convierte
asunto a texto
       df["mensaje"] = df.get("mensaje", "").astype(str) # Convierte
mensaje a texto
       df["enlaces"] = df.get("enlaces", "").astype(str) # Convierte
       df["etiqueta"] =
df["etiqueta"].astype(str).str.lower().str.strip() # Limpia etiquetas
                                                # Lista de textos
       rows = []
enriquecidos
       for _, r in df.iterrows():
                                                # Itera sobre filas del
DataFrame
           remitente = r["remitente"]  # Obtiene remitente
           asunto = r["asunto"]
                                               # Obtiene asunto
           mensaje = r["mensaje"]
enlaces_col = r["enlaces"]
                                               # Obtiene mensaje
                                                # Obtiene enlaces
           enlaces_list = []
                                                # Inicializa lista de
enlaces
           if isinstance(enlaces_col, str) and enlaces_col.strip(): # Si
hay texto en columna enlaces
               enlaces_list = [u for u in enlaces_col.split() if
u.strip()] # Separa por espacios
           enlaces_list = list(set(enlaces_list +
extraer_enlaces(mensaje))) # Añade enlaces del mensaje
           adjuntos = extraer_adjuntos(mensaje) # Extrae adjuntos del
mensaje
           enriched = self._make_feature_text(remitente, asunto, mensaje,
enlaces_list, adjuntos) # Genera texto
           rows.append(enriched)
       df["mensaje limpio"] = rows
                                                # Añade columna procesada
       self.df = df
                                                 # Guarda DataFrame
```

```
self.vectorizer = TfidfVectorizer(ngram range=(1, 2), min df=1) #
Crea vectorizador TF-IDF
       X = self.vectorizer.fit transform(self.df["mensaje limpio"])
Ajusta y transforma corpus
        self.palabras = self.vectorizer.get_feature_names_out()
Guarda vocabulario
        spam = self.df[self.df["etiqueta"] == "spam"] # Filtra spam
        ham = self.df[self.df["etiqueta"] == "ham"] # Filtra ham
        n = len(self.df) or 1
                                                     # Número total de
muestras
       self.P_spam = len(spam) / n
                                                     # Probabilidad a
priori de spam
       self.P_no_spam = len(ham) / n
                                                     # Probabilidad a
priori de ham
       X_spam = self.vectorizer.transform(spam["mensaje_limpio"]) if
len(spam) else X[:0] # Vectoriza spam
       X_ham = self.vectorizer.transform(ham["mensaje_limpio"]) if
len(ham) else X[:0] # Vectoriza ham
       alpha = 1.0
                                                     # Suavizado de Laplace
        s_spam = np.sum(X_spam.toarray(), axis=0) if X_spam.shape[0] else
np.zeros(len(self.palabras)) # Suma frecuencias spam
        s_ham = np.sum(X_ham.toarray(), axis=0) if X_ham.shape[0] else
np.zeros(len(self.palabras)) # Suma frecuencias ham
        denom_spam = (np.sum(s_spam) + alpha * len(self.palabras)) or 1.0 #
        denom_ham = (np.sum(s_ham) + alpha * len(self.palabras)) or 1.0 #
Denominador ham
        self.P_feat_spam = (s_spam + alpha) / denom_spam
Probabilidades condicionales spam
        self.P_feat_ham = (s_ham + alpha) / denom_ham
Probabilidades condicionales ham
       try:
                                                     # Calcula precisión y
recall
           self.df["prediccion"] =
self.df["mensaje_limpio"].apply(self.clasificar_texto)
            self.precision = float(np.mean(self.df["prediccion"] ==
self.df["etiqueta"]))
            denom = self.df["etiqueta"].value_counts().get("spam", 1)
           self.recall spam = float(
```

Esta clase contiene todo el funcionamiento principal del detector de spam.

Cuando se crea una instancia, el constructor:

- Carga el dataset de correos (real o de ejemplo).
- Limpia los textos con las funciones anteriores.
- Aplica TF-IDF para transformar las palabras en números.
- Calcula probabilidades de aparición de cada palabra en correos SPAM y HAM.
- Entrena un modelo basado en la Teoría de Bayes.

Funciones de Teto Enriquecido

```
======= FEATURE TEXT ========
   # ====== TEXTO ENRIQUECIDO =======
   def _make_feature_text(self, remitente: str, asunto: str, contenido:
str,
                       enlaces: list[str] | None, adjuntos:
list[tuple[str,str]] | None) -> str:
       parts: list[str] = []
                                              # Lista donde se irán
acumulando las partes del texto enriquecido
       is_dangerous = False
                                              # Bandera opcional (no
usada directamente aquí)
       # Texto base (limpio)
       parts.append(limpiar_texto(asunto))
                                             # Limpia y añade el
       contenido del mensaje
       # Dominio remitente → tokens
       dom = dominio_de_email(remitente)
                                             # Obtiene el dominio
del remitente
       parts += tokens_dominio(dom)
                                              # Genera tokens del
dominio y los agrega a la lista
```

```
# Enlaces → tokens
       if enlaces:
                                                  # Si se proporcionan
enlaces explícitamente
           for u in enlaces:
                                                  # Recorre cada enlace
               parts += tokens_enlace(u)
                                                 # Extrae tokens del
enlace
       else:
                                                 # Si no se pasaron
           for u in extraer_enlaces(contenido): # Extrae enlaces
encontrados en el cuerpo del mensaje
               parts += tokens_enlace(u) # Los convierte a
       # Adjuntos → tokens
       if adjuntos is None:
                                                  # Si no se pasaron
adjuntos explícitamente
           adjuntos = extraer_adjuntos(contenido) # Los extrae del
contenido
       adj_tokens = tokens_adjuntos(adjuntos) # Convierte los
adjuntos a tokens
       parts += adj_tokens
                                                  # Agrega los tokens de
adjuntos a la lista
       # Refuerzo para tokens peligrosos: Aumentar el peso (importancia)
       if "att_ext_dangerous" in adj_tokens: # Si hay un adjunto con
extensión peligrosa
           parts += ["att_ext_dangerous"] * 5  # Repite el token
varias veces para aumentar su peso TF-IDF
       return " ".join([p for p in parts if p]) # Une todos los tokens
en una sola cadena separada por espacios
```

Aquí se reúne toda la información del correo (asunto, cuerpo, enlaces, adjuntos, dominio, etc.) en un solo texto.

Si detecta un archivo peligroso, repite el token varias veces para aumentar su peso en el modelo TF-IDF.

Este texto final representa las "características" que usará el modelo para clasificar.

Funciones para calcular mediante la Teoría de Bayes

```
# ======= NÚCLEO BAYES ========
   def _log_post(self, txt_clean: str):
                                                   # Calcula las
probabilidades logarítmicas de SPAM y HAM
       v = self.vectorizer.transform([txt_clean]).toarray()[0] # Convierte
el texto en vector TF-IDF
       eps = 1e-12
                                                   # Valor pequeño para
evitar log(0)
       ls = np.log(self.P_spam + eps) + np.sum(np.log(self.P_feat_spam +
eps) * v) # Log probabilidad de SPAM
      lh = np.log(self.P_no_spam + eps) + np.sum(np.log(self.P_feat_ham +
eps) * v) # Log probabilidad de HAM
       return ls, lh
                                                   # Devuelve ambas
probabilidades logarítmicas
   def clasificar_texto(self, txt: str) -> str: # Clasifica un texto
cualquiera (sin formato de correo)
       t = limpiar_texto(txt)
                                                # Limpia el texto
       ls, lh = self._log_post(t)
                                                   # Calcula las
probabilidades logarítmicas
       return "spam" if ls > lh else "ham" # Retorna "spam" si su
log-probabilidad es mayor
   def prob_spam_texto(self, txt: str) -> float: # Devuelve probabilidad
numérica de ser SPAM
       t = limpiar_texto(txt)
                                                   # Limpia el texto
       ls, lh = self._log_post(t)
                                                   # Obtiene log-
probabilidades
       d = 1h - 1s
                                                   # Diferencia entre
log(HAM) y log(SPAM)
       return float(1.0 / (1.0 + np.exp(d))) # Aplica sigmoide →
valor entre 0 y 1 (probabilidad)
```

Calcula las probabilidades logarítmicas de que un mensaje pertenezca a SPAM o HAM según los tokens detectados.

El modelo compara ambos valores:

- Si la probabilidad de SPAM es mayor → clasifica como SPAM.
- Si no \rightarrow es HAM (correo legítimo).

La función clasificar texto incluye una regla de decisión la que calcula cual compara las dos probabilidades (SPAM vs HAM) y devuelve la etiqueta más probable según el modelo.

Funciones para correo

```
====== FUNCIONES PARA CORREO =======
   def clasificar correo(self, remitente: str, asunto: str, contenido: str)
-> str:
       Compatibilidad retro: extrae enlaces/adjuntos automáticamente del
contenido.
       enriched = self._make_feature_text(remitente, asunto, contenido,
None, None) # Genera texto enriquecido
       ls, lh = self._log_post(enriched)
                                                      # Calcula
probabilidades logarítmicas
       return "spam" if ls > lh else "ham"
                                             # Devuelve etiqueta
según probabilidad mayor
   def prob_spam_correo(self, remitente: str, asunto: str, contenido: str)
-> float:
       enriched = self. make feature text(remitente, asunto, contenido,
None, None) # Texto enriquecido
                                                       # Probabilidades
       ls, lh = self. log post(enriched)
                                                       # Diferencia
       d = 1h - 1s
logarítmica
       return float(1.0 / (1.0 + np.exp(d)))
                                                       # Devuelve
probabilidad de ser SPAM
   # Versión extendida (puedes pasar enlaces y adjuntos ya extraídos desde
la UI)
   def clasificar_correo_ext(self, remitente: str, asunto: str, contenido:
str,
                             enlaces: list[str] | None = None,
                             adjuntos: list[tuple[str,str]] | None = None)
-> str:
       enriched = self._make_feature_text(remitente, asunto, contenido,
enlaces, adjuntos) # Texto enriquecido con todo
       ls, lh = self._log_post(enriched)
                                                       # Calcula
probabilidades logarítmicas
       return "spam" if ls > lh else "ham"
                                             # Clasifica como
SPAM o HAM
   def prob_spam_correo_ext(self, remitente: str, asunto: str, contenido:
str,
```

Esta sección del programa contiene las funciones encargadas de analizar y clasificar los correos electrónicos ingresados por el usuario o por una interfaz gráfica.

En otras palabras, actúa como una interfaz directa entre el modelo de detección de spam y el usuario final, permitiendo determinar si un correo es legítimo (HAM) o no deseado (SPAM) a partir de los datos proporcionados.

El método principal, clasificar_correo(), recibe como parámetros el remitente, el asunto y el contenido del correo.

Internamente, esta función extrae automáticamente los enlaces y archivos adjuntos del texto y genera un texto enriquecido mediante la función _make_feature_text(), que combina todos los elementos relevantes del mensaje (dominio, enlaces, palabras clave, extensiones de archivos, etc.).

Luego, con ayuda del método _log_post(), el sistema calcula las probabilidades logarítmicas de que el mensaje pertenezca a la clase SPAM o HAM.

Finalmente, compara ambos valores y devuelve la etiqueta final ("spam" o "ham") según la probabilidad más alta.

De forma complementaria, la función prob_spam_correo() realiza el mismo proceso, pero devuelve un valor numérico entre 0 y 1, que representa la probabilidad de que el mensaje sea spam.

Esto se logra aplicando una función matemática sigmoide que transforma las probabilidades en un número interpretativo.

Por ejemplo, un valor cercano a 1 indica alta probabilidad de ser SPAM, mientras que uno próximo a 0 sugiere que el correo es legítimo.

El programa también incluye versiones extendidas de ambas funciones:

```
clasificar_correo_ext() y prob_spam_correo_ext().
```

Estas permiten pasar manualmente los enlaces y adjuntos ya detectados desde una interfaz externa, evitando que el programa los busque nuevamente.

Archivo de Config regex.py

```
# Configuraciones de expresiones regulares
import re # Importa el módulo estándar para trabajar con expresiones
regulares en Python
# --- Detecta URLs (enlaces) ---
URL_RE = re.compile(
    r"(https?://[^\s]+)", # Busca cadenas que empiecen con http:// o
https:// seguidas de cualquier carácter no espacio
    re.IGNORECASE
                         # Ignora mayúsculas/minúsculas al comparar (por
ejemplo, HTTP o http)
# --- Detecta nombres de archivos adjuntos en texto ---
ADJUNTO_RE = re.compile(
    r"(?<!\S)" # Asegura que antes no haya un carácter no-espacio (inicio
de palabra o después de un espacio)
    r''(P<name)(?:[\w\-\(\)\[\]&]+(?:[\t]+[\w\-\(\)\[\]&]+)*)\." # Captura
el nombre del archivo antes del punto
    r"(?P<ext>[A-Za-z0-9]{1,6}))" # Captura la extensión (1 a 6
letras/números)
    r"(?=$|[\s\)\]\.,;:!?])", # Asegura que después venga un espacio,
puntuación o final del texto
    re.UNICODE # Soporta caracteres Unicode en los nombres
# --- Conjuntos de extensiones de archivos ---
EXT_PELIGROSAS = { # Extensiones asociadas a ejecutables o scripts
peligrosos
    "exe", "bat", "cmd", "js", "vbs", "scr", "msi", "jar",
    "iso", "lnk", "ps1", "apk", "reg"
EXT_COMUNES = { # Extensiones típicas de documentos y archivos comprimidos
    "zip", "rar", "7z", "pdf", "doc", "docx", "docm",
    "xls", "xlsx", "xlsm", "ppt", "pptx", "pptm",
  --- Validación básica de correos electrónicos ---
```

```
EMAIL_RE = re.compile(
    r"^[^@\s]+@[^@\s]+\.[^@\s]+$", # Patrón: algo@algo.algo sin espacios
)
def es_email_valido(s: str) -> bool:
    """Devuelve True si el correo tiene un formato válido (mínimo
algo@algo.algo)."""
    return bool(EMAIL_RE.match((s or "").strip())) # Limpia espacios y
verifica coincidencia con el patrón
```

Se tienen las configuraciones de expresiones regulares en donde se tienen extensiones peligrosas o comunes para asi detectar los archivos adjuntos peligrosos.

Archivo de Interfaz Gráfica

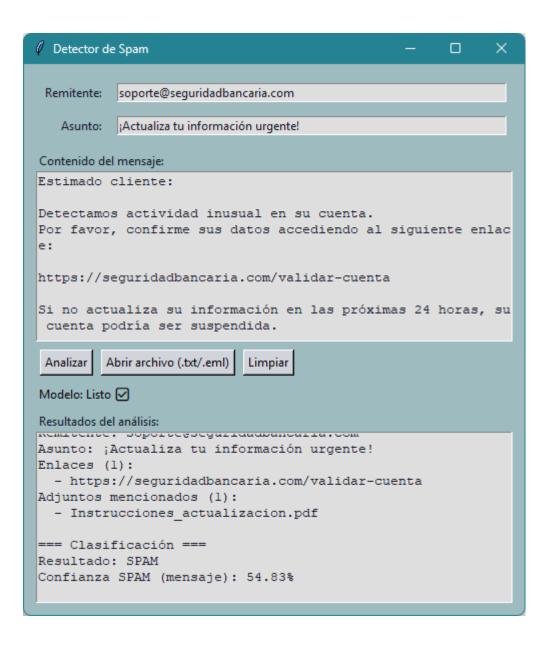
```
import re, threading # re: expresiones regulares; threading: ejecutar carga
del modelo en segundo plano
from pathlib import Path # Manejo de rutas de archivos de forma
multiplataforma
import tkinter as tk # Tkinter base
from tkinter import filedialog, messagebox # Diálogos para abrir archivos y
mostrar mensajes
from DeteccionDeSpam import EmailSpamClassifier # backend # Importa el
clasificador del backend
from Config_regex import URL_RE, ADJUNTO_RE, EXT_PELIGROSAS, EXT_COMUNES,
es email valido # Carga regex/sets/validador
# ====== Colores UI ====== # Paleta de colores para la interfaz
COLOR BG = "#9ebbc0" # Color de fondo general
COLOR_INPUT = "#dfdede" # Color de fondo para entradas de texto
COLOR_TEXT = "#111827" # Color de texto principal
# ====== Ventana principal ====== # Configuración de la ventana raíz
root = tk.Tk() # Crea la ventana principal
root.title("Detector de Spam") # Título de la ventana
root.geometry("500x550") # Tamaño inicial de la ventana
root.configure(bg=COLOR_BG) # Aplica color de fondo
```

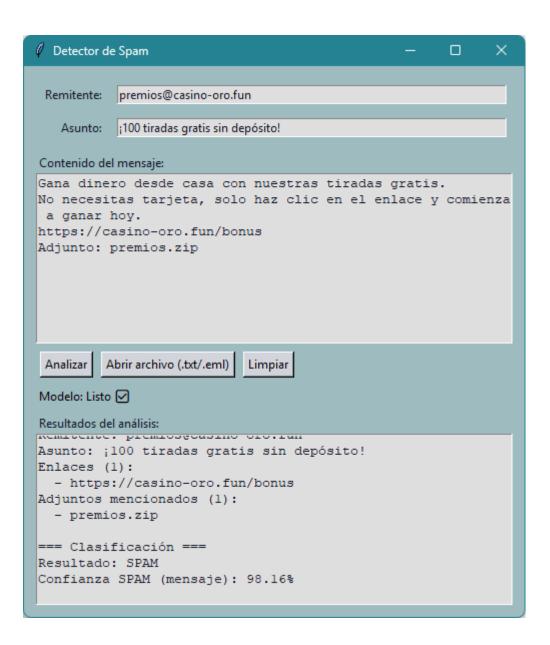
El resto del código es parte de la interfaz gráfica que no se considero necesario mostrar ya que solo se muestra cómo se creó el frame.

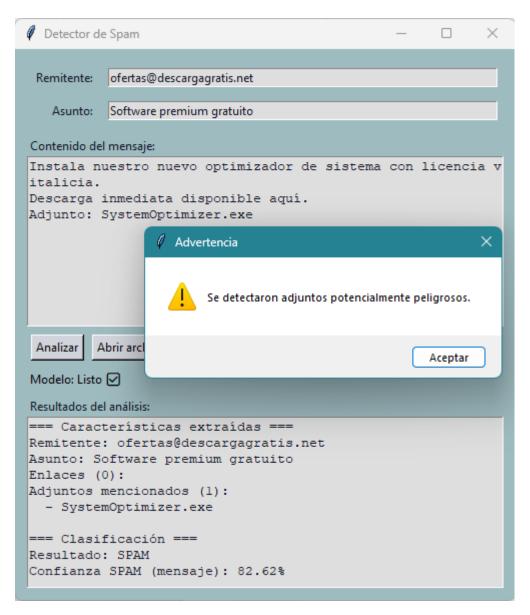
Pruebas del código

El código se inicia desde la clase de la Interfaz Gráfica:









En esta prueba se detectó un archivo adjunto con una extensión peligrosa por lo cual manda un mensaje de advertencia.



